



第四章 自适应滤波

1. 概念


自适应滤波: 根据信号环境特性用递归算法(自适应算法)自动调整滤波器的脉冲响应, 使自适应滤波器输出尽可能接近其期望输出。

在平稳环境中, 迭代次数充分大时, 自适应算法给出的结果在某种统计意义上收敛于最佳维纳解。在非平稳环境中, 自适应算法具有一定跟踪输入数据统计特性(缓慢)变化的能力。



完整结构

2. 自适应滤波器的结构



(只能算是一个普通滤波器)

(权重系数) (通过误差) 可变 (来调整)

$$\mathbf{X}(n) = \begin{pmatrix} x(n) \\ x(n-1) \\ \vdots \\ x(n-N+1) \end{pmatrix}$$


输入向量

$$\mathbf{X}(n) = \begin{pmatrix} x_1(n) \\ x_2(n) \\ \vdots \\ x_{N-1}(n) \end{pmatrix}$$

(N-1个输入)

$$\mathbf{W}_n = \begin{pmatrix} w_0(n) \\ w_1(n) \\ \vdots \\ w_{N-1}(n) \end{pmatrix}$$


权向量



输出:

(标量) $y(n) = W^T(n) \mathbf{z}(n) = \mathbf{z}^T(n) \cdot W(n)$ (内积)

自适应滤波器:




完整带反馈的
简略框图.

自适应算法: $\begin{cases} \text{随机梯度算法 (LMS 算法)} & (\text{误差统计平均最小}) \\ \text{最小二乘算法 (RLS 算法)} & (\text{误差时间平均最小}) \end{cases}$

自适应滤波的应用:


1. 系统辨识



$$\hat{y}_x(n) = \hat{x}_x(n) * h(n) = \hat{x}_x^2(n) * h(n) = \hat{x}_x^2(n) h(n)$$

$$h(n) = \frac{1}{\hat{x}_x^2} \cdot \hat{y}_x(n)$$

2. 自适应降噪

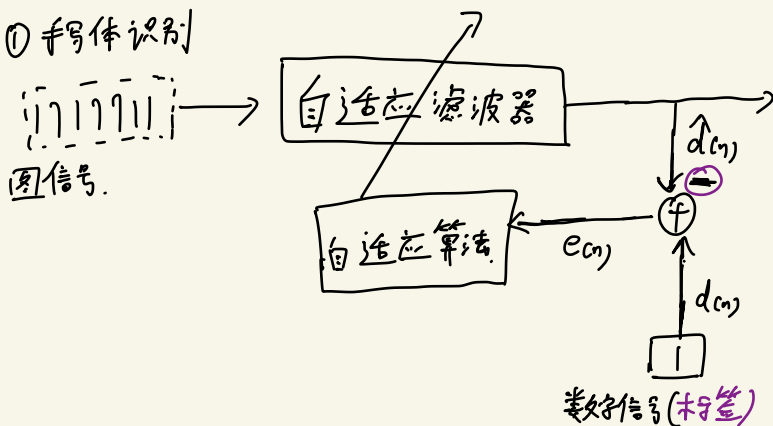


通过足够的迭代,使误差
极限小,就可认为两个输出相
等,即两个系统近似相等.

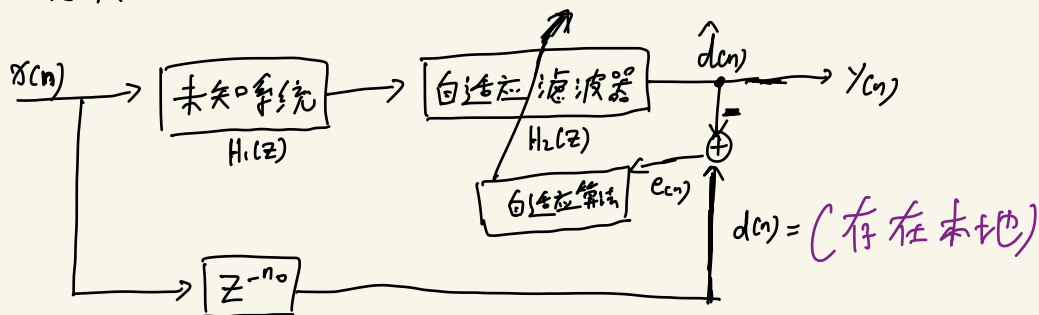
应用 $\begin{cases} \text{① 手写体识别} \\ \text{② 逆滤波} \end{cases}$

自适应滤波的应用:

① 手写体识别



② 逆滤波



理想信道: $H(z) = 1$, $h(n) = \delta(n)$; 因为有延迟, 所以只要求 (理想)

(要求输出 = 输入, $Y(z) = H(z)X(z)$)

即 $y(n) = x(n)$

$H(z) = z^{-n_0}$, $h(n) = \delta(n - n_0)$

即 $y(n) = x(n - n_0)$

实际:

$H_1(z) = z^{-n_0}$, 估不到

加上 $H_2(z)$ 使得 $H_1(z) \cdot H_2(z) = z^{-n_0}$



待发送的实际数据



训练数据, 可存储在接收端

训练结束时, 得到训练好的权向量

即使 $H_1(z) \cdot H_2(z) \approx z^{-n}$



算法收敛快, 训练数据长度趋向无穷, 信道使用率趋向高.

改进: 在信号处理里, 不用训练数据.
(可提高信道效率, 但是精度不如上述方法高)

自适应算法.

1. 最速下降法 (LMS 算法的基础)

$$J(w) = E(e^2(n)) = d^2 - 2w^T P + w^T R w$$

(目标代价函数)

$$w(n+1) = w(n) + \Delta w = ?$$

$$J(w+\Delta w) = J(w) + \sum_{i=0}^{N-1} \frac{\partial J}{\partial w_i} \Delta w_i + \frac{1}{2} \sum_{i=0}^{N-1} \sum_{j=0}^{N-1} \Delta w_i \frac{\partial^2 J}{\partial w_i \partial w_j} \Delta w_j + \dots$$

$$= J(w) + (\Delta w)^T \nabla J(w) + \frac{1}{2} (\Delta w)^T \nabla^2 J(w) (\Delta w) + \dots$$

(新向量)

其中 $\nabla J(w) = -2P + 2RW$ (求导)

$\nabla^2 J(w) = 2R$ (二阶导)

R 通常正定, 所以

$$(\Delta w)^T \nabla^2 J(w) (\Delta w) > 0$$

若要减小代价函数, 即使 $(\Delta w)^T \nabla J(w) < 0$
($J(w+\Delta w) < J(w)$)

$$\therefore (\Delta w)^T \nabla J(w) = \|\Delta w\| \|\nabla J(w)\| \cos \theta$$

\therefore 当 $\cos \theta = -1$ 时, $(\Delta w)^T \nabla J(w)$ 为负值, 且最小.

此时 $\Delta w = -\nabla J(w) = 2P - 2RW$, $J(w+\Delta w)$ 的减小量最大.
($\theta = \pi$)

\therefore 负梯度方向是最速下降式.


$$w(n+1) = w(n) + \Delta w = w(n) + \mu [-\nabla J(w)]$$

$\mu > 0$, 称为步长参数. (控制算法收敛速度)

μ 变大, 迭代速度变快, 但是 μ 过大, 会导致发散 (来回振荡)

μ (可以控制算法的稳定性和收敛速度)

确定一个 μ 的范围, 使算法收敛 ($\lim_{n \rightarrow \infty} w(n) = w_{opt}$) ???



$$E(c^*) = J(w) = 6a^2 - 2w^T P + w^T R w$$

$$\nabla J(w_{cn}) = 2R w_{cn} - 2P \quad \text{对 } w \text{ 求导}$$

$$w_{cn+1} = w_{cn} + 2H[P - R w_{cn}]$$

$$= (I - 2HR) w_{cn} + 2HP$$

(2HR w_{opt})

$$w_{opt} = R^{-1}P$$

↓

$$P = R w_{opt}$$

坐标平移:

$$\tilde{w}_{cn} = w_{cn} - w_{opt}$$

↓ 0 ↓ 最优

$$\tilde{w}_{cn+1} = (I - 2HR) w_{cn} + 2HR w_{opt} - w_{opt}$$

$$= (I - 2HR) w_{cn} - (I - 2HR) w_{opt}$$

$$= (I - 2HR) (w_{cn} - w_{opt})$$

$$= (I - 2HR) \tilde{w}_{cn}$$

$$\tilde{w}_{cn+1} = (I - 2HR)^n \tilde{w}_{c0}$$

要求: $n \rightarrow \infty, \tilde{w}_{cn+1} \rightarrow \begin{bmatrix} 0 \\ \vdots \\ 0 \end{bmatrix}$

① $(I - 2HR)$ 为 1 维的时候, 只需让其小于 1 即可, n 次方后趋向于 0

② $(I - 2HR)$ 为 2 维矩阵时, 因其内部数据太多, 无法观察,

③ $(I - 2HR)$ 转换为对角矩阵, 只需考虑对角线元素即可。

转换要
对角化

坐标旋转: $V_{cn} = Q^T \tilde{w}_{cn} = Q^{-1} \tilde{w}_{cn}, \quad (R = Q \Lambda Q^T)$

$$\tilde{w}_{cn} = Q V_{cn}$$

$$Q V_{cn+1} = (I - 2HR) \tilde{w}_{cn} = (I - 2HR) Q V_{cn}$$

$$Q^{-1} Q V_{cn+1} = Q^{-1} (I - 2HR) Q V_{cn}$$

$$V_{cn+1} = Q^{-1} (I - 2HR) Q V_{cn}$$

$$\begin{aligned}
 V_{(n+1)} &= Q^{-1}(I - 2\mu R)Q V_{(n)} \\
 &= (I - 2\mu Q^{-1}RQ) V_{(n)} \\
 &= (I - 2\mu \Lambda) V_{(n)} \\
 &\vdots
 \end{aligned}$$

$$\underline{V_{(n)}} = (I - 2\mu \Lambda)^n V_{(0)}$$

要求 $n \rightarrow \infty$, $V_{(n)} \rightarrow \begin{bmatrix} 0 \\ \vdots \\ 0 \end{bmatrix}$

$$\begin{bmatrix} V_{0(n)} \\ V_{1(n)} \\ \vdots \\ V_{N-1(n)} \end{bmatrix} = \begin{bmatrix} (1 - 2\mu \lambda_0)^n & & \\ & (1 - 2\mu \lambda_1)^n & \\ & & \ddots \\ & & & (1 - 2\mu \lambda_{N-1})^n \end{bmatrix} \begin{bmatrix} V_{0(0)} \\ V_{1(0)} \\ \vdots \\ V_{N-1(0)} \end{bmatrix}$$

在特征标系下, 变量不再耦合。

$$V_{k(n)} = (1 - 2\mu \lambda_k)^n V_{k(0)}$$

$$k = 0, 1, \dots, N-1$$

k 与 $k-1, \dots$ 无关。
解耦

收敛要求: $|1 - 2\mu \lambda_k| < 1$

$$-1 < (1 - 2\mu \lambda_k) < 1$$

$$-2 < -2\mu \lambda_k < 0$$

$$1 > \mu \lambda_k > 0$$

$$0 < \mu < \frac{1}{\lambda_k}, \quad k = 0, \dots, N-1$$

满足所有:

$$\lambda \quad 0 < \mu < \frac{1}{\lambda_{\max}}, \quad \text{此时算法收敛。}$$

此时, $\lim_{n \rightarrow \infty} V_{(n)} = \begin{bmatrix} 0 \\ \vdots \\ 0 \end{bmatrix}$


即 $\lim_{n \rightarrow \infty} Q^T(W_{(n)} - W_{\text{opt}}) = \begin{bmatrix} 0 \\ \vdots \\ 0 \end{bmatrix} \implies \lim_{n \rightarrow \infty} W_{(n)} = W_{\text{opt}}$

$$J(n) = J_{\min} + \sum_{k=0}^{n-1} \lambda_k (V_k(n))^2$$

$$= J_{\min} + \sum_{k=0}^{n-1} \lambda_k (1 - 2H\lambda_k)^{2n} V_k(0)^2$$

指数曲线的加权和

曲线 $J(n) \sim n$ 称为学习曲线



$$J(n) \leq \left[\frac{\text{cond}(R) - 1}{\text{cond}(R) + 1} \right]^2 J(n-1)$$

$\text{cond}(R)$ 是相关矩阵 R 的条件数.

$$\text{cond}(R) = \frac{\lambda_{\max}}{\lambda_{\min}} > 1, \text{ 越小越好.}$$

越小收敛越快.

当 $R = \begin{bmatrix} \cdot & \cdot & 0 \\ & \cdot & \\ 0 & & \cdot \end{bmatrix}$

$\therefore J(n)$ 是白噪声 $\lambda_{\max} = \lambda_{\min}$, 收敛最快

λ_{\max} 对应的特征向量 q_{\max} 和 λ_{\min} 对应的特征向量 q_{\min}


给出了均方误差的 ^{下界} 最大和 ^{上界} 最小曲线方向.

等高线 (有相同的均方误差) 越扁, 收敛速度越慢.


越圆, 收敛速度越快.

$J(n)$ 下降的等效时间常数, τ_k 为下降为初始值的 $\frac{1}{e}$ 所用的时间 (迭代次数)

即用 $e^{-\frac{n}{\tau_k}}$ 近似 $(1 - 2H\lambda_k)^{2n}$



即用 $e^{-\frac{1}{\tau_k}}$ 近似 $(1-2H\lambda_k)^{2n}$



$$(1-2H\lambda_k)^2 = e^{-\frac{1}{\tau_k}} \approx \underline{1 - \frac{1}{\tau_k}} \quad (e^x \approx 1+x)$$

当 n 很大时,

$$(1-2H\lambda_k)^2 \approx \underline{1 - 2 \cdot 2H\lambda_k}$$

$$\therefore \tau_k \approx \frac{1}{4H\lambda_k}$$

学习曲线是 N 个指数曲线 (对应不同的 λ_k) 的加权和。

$$\therefore \tau \approx \frac{1}{4H\lambda_{\min}}$$

$$\therefore 0 < H < \frac{1}{\lambda_{\max}}$$

$$\therefore \frac{1}{H} > \lambda_{\max}$$

$$\therefore \tau \approx \frac{1}{4\lambda_{\min}} \cdot \frac{1}{H} > \frac{1}{4} \frac{\lambda_{\max}}{\lambda_{\min}} = \frac{1}{4} \text{cond}(R)$$

如果相关矩阵 R 的特征值动态范围很大 (R 为病态矩阵)
(条件数很大)

收敛很慢,

$$Ax = b$$

$$x = A^{-1}b$$

$$A \leftarrow A + \Delta A$$

误差

$$x \leftarrow x + \Delta x$$

如果 $\| \Delta A \|$ 小, $\| \Delta x \|$ 也小, 良态

$\| \Delta A \|$ 小, $\| \Delta x \|$ 变大, 病态 (有放大效应)

↑↑↑

(越大矩阵, 越容易出现病态)

$$W_{(n+1)} = W_{(n)} + \mu [-\nabla J(W_{(n)})]$$

$$= W_{(n)} + 2\mu [P - RW_{(n)}], \quad n \text{ 是迭代次数. 不是时间. 不是一个自适应算法.}$$

仅仅是 $W_{opt} = R^{-1}P$ 的迭代实现。

- 都要知道统计特性. P, R
- ① $W_{opt} = R^{-1}P$, 一次性需要 矩阵求逆
 - ② $W_{(n+1)} = W_{(n)} + 2\mu (P - RW_{(n)})$ 多次迭代, 无矩阵求逆.

4.3 最小均方(LMS)算法

$$P = E[\mathbf{z}(n)\mathbf{z}^T(n)]$$

$$R = E[\mathbf{z}(n)\mathbf{z}^T(n)]$$

为了计算简单,用目前时值代替平均.

本梯度的目前时估计为:

$$\hat{\nabla} J(w) = 2\mathbf{z}(n)\mathbf{z}^T(n)\hat{w}(n) - 2\mathbf{z}(n)d(n)$$

$$\text{对66 } \nabla J(w) = 2Rw(n) - 2P \quad \uparrow \text{ 去掉取平均}$$

$$= 2E[\mathbf{z}(n)\mathbf{z}^T(n)]w(n) - 2E[\mathbf{z}(n)d(n)]$$

$$\hat{\nabla} J(w) = -2\mathbf{z}(n) \left[d(n) - \underbrace{\mathbf{z}^T(n)\hat{w}(n)}_{\hat{d}(n)=y(n)} \right]$$

$$= -2\mathbf{z}(n)e(n)$$

△MS:

$$y(n) = \hat{w}^T(n)\mathbf{z}(n) \quad N \text{ 次乘, } N-1 \text{ 次加}$$

$$e(n) = d(n) - y(n) \quad 1 \text{ 次加}$$

$$\hat{w}(n+1) = \hat{w}(n) + 2\mu \mathbf{z}(n)e(n) \quad (n \text{ 是时间, 所以是自适应算法})$$

列向量 标量 列向量 标量

N+1 次乘, N 次加

总: 2N+1 次乘, 2N 次加

$O(N)$ 时间复杂度

优: 计算量小

缺: 收敛缓慢

在一定条件下, 如果 $0 < \mu < \frac{1}{\lambda_{\max}}$, 则 LMS 算法均方收敛:

$$\lim_{n \rightarrow \infty} E[w(n)] = w_{\text{opt}} \quad \lim_{n \rightarrow \infty} E[\|\hat{w}(n) - w_{\text{opt}}\|^2] = \text{常数} a$$

$$\therefore \lambda_{\max} < \text{tr}[R] = \lambda_0 + \lambda_1 + \dots + \lambda_{N-1} \quad (\lambda > 0)$$

$\therefore \mu$ 也可保守地取为

$$0 < \mu \leq \frac{1}{\text{tr}[R]}$$

$\text{tr}[R]$ 是车前 λ 向量 $\mathbf{z}(n)$ 的输入功率

一定条件: 假定 $\mathbf{z}(n), \mathbf{z}(n+1), \mathbf{z}(n-1), \dots$ 互不相关。 \rightarrow 估计不到

$$\mathbf{z}(n) = \begin{bmatrix} z(n) \\ z(n-1) \\ \vdots \\ z(n-N+1) \end{bmatrix} \quad \mathbf{z}(n+1) = \begin{bmatrix} z(n+1) \\ z(n) \\ \vdots \\ z(n-N+2) \end{bmatrix}$$

$\rightarrow \mathbf{z}(n), \mathbf{z}(n+1)$ 是相关的

两种不同的车前方式。

$$\text{若 } \mathbf{z}(n) = \begin{bmatrix} z_0(n) \\ z_1(n) \\ \vdots \\ z_{N-1}(n) \end{bmatrix} \quad \mathbf{z}(n+1) = \begin{bmatrix} z_0(n+1) \\ z_1(n+1) \\ \vdots \\ z_{N-1}(n+1) \end{bmatrix}$$

此时 $\mathbf{z}(n), \mathbf{z}(n+1)$ 可能不相关

(白噪声) \nearrow 要求很苛刻。

$\angle MS$ 算法的均方误差:

$$J(n) = J_{\min} + J_{\text{tr}}(n) + J_{\text{ex}}(\infty)$$

J_{\min} 是王理论上的最小均方误差。

$J_{\text{tr}}(n)$ 是跟踪均方误差, $J_{\text{tr}}(n=\infty)=0$ 。

$J_{\text{ex}}(\infty)$ 是稳态超量均方误差, 由梯度噪声产生的 (用 $\hat{\mathbf{d}}$ 代替 \mathbf{d})

($\hat{\mathbf{d}} = \mathbf{d} + \text{噪声}$)

在稳态时 ($n=\infty$)

$$J(\infty) = J_{\min} + J_{\text{ex}}(\infty) > J_{\min}$$

性能变差 \rightarrow 次最优解。

$$\mu \text{ 很小的时候 } J_{\text{ex}}(\infty) \approx \mu \cdot \text{tr}[R] \cdot J_{\min}$$

$\therefore \mu$ 越小, $J_{\text{ex}}(\infty)$ 越小, 但收敛速度变慢。

失调量定义为

$$M = \frac{T_{\text{ex}}(\infty)}{T_{\text{min}}} \approx H \text{ tr} [R]$$

在标准 LMS 算法中

$$\hat{W}_{(n+1)} = \hat{W}_{(n)} + 2\mu e(n) z(n)$$

收敛很慢

改进: ① 归一化的 LMS 算法


$$\hat{W}_{(n+1)} = \hat{W}_{(n)} + 2\mu(n) e(n) z(n), \quad \mu(n) = \frac{\tilde{\mu}}{\|z(n)\|}, \quad 0 < \tilde{\mu} < 1$$

② 对输入矢量 $z(n)$ 作变换, 去掉其相关性 (白化), 减小其特征值的动态范围, 从而提高收敛速度.

③ 子带域自适应.


可以证明: 功率谱的最大值与最小值之比相当于相关矢矩阵的最大特征值与最小特征值之比.

$$\frac{P_{xx}(w)_{\max}}{P_{xx}(w)_{\min}} \approx \frac{\lambda_{\max}}{\lambda_{\min}}$$



频率分割, 可减小特征值的波动范围.

白噪声:



$$P_w(w) = \sigma_w^2$$

$$\frac{P_w(w)_{\max}}{P_w(w)_{\min}} = 1$$

$$\frac{\lambda_{\max}}{\lambda_{\min}} = 1$$

FFT