


$$x(n) \rightarrow \boxed{h(n)} \rightarrow y(n)$$

$$① y(n) = x(n) * h(n) = \sum_{k=-\infty}^{\infty} h(n-k) x(k)$$

$$② \phi_{yy}(m) = \phi_{xx}(m) * h(m) * h(-m) = \phi_{xx}(m) * h(-m)$$

$$③ P_{yy}(w) = P_{xx}(w) \cdot H(w) \cdot H^*(w) = P_{xx}(w) |H(w)|^2$$

$$④ \phi_{xx}(m) \longleftrightarrow P_{xx}(w) \text{ (傅里叶)} \quad \phi_{xx}(m) \xleftrightarrow{Z} \bar{\Phi}_{xx}(z)$$

$$⑤ P_{xx}(w) = \bar{\Phi}_{xx}(z) / z = e^{jw}$$

$$\phi_{xx}(m)$$

$$① \text{对称} \quad ② \text{斜对角线元素相等} \quad ③ R \text{ 为非负定}$$

$$④ \phi_{xx}(0) \text{ 最大为正数} \quad (\phi_{xx}(0) = m_x^2 + \sigma_x^2)$$

$$⑤ \phi_{xx}(m) \text{ 为实数}$$

$$P_{xx}(w)$$

$$① \text{非负} \quad ② \text{实偶函数} \quad ③ 2\pi \text{ 为周期}$$

$$\text{相关卷积定理}$$

$$\begin{cases} e = a * b \\ f = c * d \end{cases} \quad \phi_{ef}(w) = \phi_{ac}(w) * \phi_{bd}(w)$$

Vina

1. 维纳-霍夫方程

$$\phi_{xs}(k) = \sum_{m=0}^{\infty} h_{opt}(m) \phi_{ss}(k-m) \quad k \geq 0$$

2. 维纳滤波 (时)

$$\begin{aligned} J(w) &= E[e_n^2] = d^2 - 2P^T w + w^T R w \\ J_{min} &= d^2 - P^T w_{opt} = d^2 - w_{opt}^T P \quad (w_{opt} \text{ 为最优向量}) \quad (大误差) \\ w_{opt} &= R^{-1} P \Rightarrow P = R \cdot w_{opt} \\ R &= E[x(n)x^T(n)], \quad P = E[x(n)d(n)] \end{aligned}$$

3. 维纳滤波 (频) (习题)

$x = s + v$, s 与 v 不相关

$$\begin{aligned} ① \quad \Phi_{xs}(z) &= \sigma_w^2 B(z) B(z^{-1}) \\ ② \quad H_{opt}(z) &= \frac{1}{\sigma_w^2 B(z)} \left[\frac{\Phi_{xs}(z)}{B(z^{-1})} \right]_+ \quad \text{因果} \quad \left(H_{opt} = \frac{\Phi_{xs}(z)}{\Phi_{ss}(z)} \text{ 非因果} \right) \\ ③ \quad E[e_n^2]_{min} &= \frac{1}{2\pi j} \oint [\Phi_{ss}(z) - H_{opt}(z) \cdot \Phi_{xs}(z^{-1})] z^{-1} dz \end{aligned}$$

4. 因果维纳预测值 (N步) $(v=0)$ $d(n) = s_{n+N}$

$$\begin{aligned} ① \quad \Phi_{xs}(z) &= \Phi_{ss}(z) = \Phi_{ss}(z) = \sigma_w^2 B(z) B(z^{-1}) \\ ② \quad H_{opt}(z) &= \frac{1}{\sigma_w^2 B(z)} \left[\frac{\Phi_{xs}(z)}{B(z^{-1})} \cdot z^N \right] = \frac{1}{B(z)} \left[z^N B(z) \right]_+ \\ &\quad \downarrow \\ &\quad b_{n+N} h_{cn} \\ ③ \quad J_{min} &= \sigma_w^2 \sum_{k=0}^{N-1} b^2(k) \end{aligned}$$

$$④ \quad a_{pk} = -h(k-1) \quad (P \text{ 步预测}) \quad (\text{Yule-walker 方程})$$

LS

$$① y_{cn} = \hat{w}_{cn}^T z_{cn}$$

$$② e_{cn} = d_{cn} - y_{cn}$$

$$③ \hat{w}_{c(n+1)} = \hat{w}_{cn} + 2\mu z_{cn} e_{cn}$$

$$④ \nabla J(w) = -2 z_{cn} e_{cn}$$

最速下降法

$$0 < \mu < \frac{1}{\lambda_{\max}}, \lambda \text{ 为 } R \text{ 的特征值}$$

$$w_{c(n+1)} = w_{cn} + \mu [-\nabla J(w_{cn})]$$

$$= w_{cn} + 2\mu [P - R w_{cn}]$$

$$\nabla J(w) = -2P + 2R w_{cn}$$

谱估计

1. 经典: BT法

$$\hat{\Phi}'_{xx}(m) = \frac{1}{N-|m|} \sum_{n=0}^{N-1-|m|} x_{cn} x_{c(n+m)}, \text{ 无偏, 方差大}$$

$$\bar{\Phi}_{xx}(m) = \frac{1}{N} \sum_{n=0}^{N-1-|m|} x_{cn} x_{c(n+m)}, \text{ 有偏, 方差小, 均方误差小}$$

2. 周期图法

$$Z_N(e^{j\omega}) = \sum_{n=0}^{N-1} x_{cn} e^{-j\omega n}$$

$$I_N(\omega) = \frac{1}{N} |Z_N(e^{j\omega})|^2, \text{ 有偏, 不是一致估计}$$

$$\hat{P}_{xx}(\omega) = I_N(\omega)$$

改进

Bartlett 平均周期图法, 方差降为原来的 $\frac{1}{L}$.

Yule-walker

$$\begin{bmatrix} \bar{\Phi}_{xx}(0) & \bar{\Phi}_{xx}(-1) & \bar{\Phi}_{xx}(-2) \\ \bar{\Phi}_{xx}(1) & \bar{\Phi}_{xx}(0) & \bar{\Phi}_{xx}(-1) \\ \bar{\Phi}_{xx}(2) & \bar{\Phi}_{xx}(1) & \bar{\Phi}_{xx}(0) \end{bmatrix} \begin{bmatrix} 1 \\ a_{p1} \\ a_{p2} \end{bmatrix} = \begin{bmatrix} E[e^2]_{\min} \\ 0 \\ 0 \end{bmatrix}$$

= 预测

$$w(n) \rightarrow \boxed{h(n)} \rightarrow x(n)$$

3. 参数化模型

ARMA (p, q)

MA (q)

AR (p)

$$\rightarrow H(z) = \frac{1}{1 + \sum_{k=1}^p a_k z^{-k}}$$

$$x(n) = - \sum_{k=1}^p a_k x(n-k) + w(n)$$

$$\hat{P}_{xx}(w) = \sigma_w^2 |H(w)|^2$$

1. 宽平稳 (广义平稳)

- ① 均值为常数, $E[x(n)] = m_x$, 与 n 无关
- ② 自相关函数只与时间间隔 m 相关, 与 n 无关. $\rightarrow E[x(n_1)x(n_2)] = b_{xx}(n_2 - n_1) = b_{xx}(m)$

2. 判自相关函数 (页15, 页16)

$$b_{xx}(m) = E[x(n)x(n+m)]$$

- 性质
- ① $b_{xx}(m) = b_{xx}(-m)$
 - ② $b_{xx}(0)$ 最大, 且为正.
 - ③ $b_{xx}(0) = m_x^2 + b_x^2$
 - ④ 若 $x(n)$ 不含周期分量, 则 $b_{xx}(\infty) = m_x^2$

3. 判自相关矢矩阵 (页14)

$$R = E[x(n)x^T(n)] = \begin{bmatrix} b_{xx}(0) & b_{xx}(1) & \dots & b_{xx}(1-n) \\ b_{xx}(1) & b_{xx}(0) & \dots & \vdots \\ \vdots & \vdots & \ddots & b_{xx}(-1) \\ b_{xx}(n-1) & \dots & b_{xx}(1) & b_{xx}(0) \end{bmatrix}$$

$$x(n) = \begin{pmatrix} x(n) \\ x(n-1) \\ \vdots \\ x(1) \end{pmatrix}$$

- 性质
- ① R 为对称矩阵
 - ② R 为 Toeplitz 矩阵 \rightarrow 每条对角线上的元素分别相等
 - ③ R 为非负定
 - ④ $b_{xx}(0)$ 最大
 - ⑤ $b_{xx}(m)$ 为实数

4. 时间平均

$$\langle x_n \rangle \triangleq \lim_{N \rightarrow \infty} \frac{1}{2N+1} \sum_{n=-N}^N x(n)$$

$$\langle x_n x_{n+m} \rangle \triangleq \lim_{N \rightarrow \infty} \frac{1}{2N+1} \sum_{n=-N}^N x(n) x(n+m)$$

各态历经

$$\begin{aligned} &= m_x \\ &= b_{xx}(m) \end{aligned}$$

依根率1 成立 \rightarrow

$\langle x_n \rangle$

m_x

所以只有各态历经, 才可以用 时间平均 来代替 集合平均.

CP5: 一般证明一个随机过程, 若满足 $E[x(n)] = m_x$ 即广义平稳, 但 $\langle x_n \rangle \neq m_x$, 即非各态历经。
| $E[x(n)x(n+k)] = \sigma_{xx}(k)$

5. 自功率谱 (页17)

(平稳随机信号) (不过一般默认平稳)

$$\begin{aligned} P_{xx}(w) &= \sum_{m=-\infty}^{\infty} \sigma_{xx}(m) e^{-jwm} \rightarrow P_{xx}(w) \text{ 与 } \sigma_{xx}(m) \text{ 互为傅里叶变换对.} \\ \sigma_{xx}(m) &= \frac{1}{2\pi} \int_{-\pi}^{\pi} P_{xx}(w) e^{jwm} dw \end{aligned}$$

↓ 离散域用Z变换

性 { ① 非负实数 ② $P_{xx}(w) = P_{xx}(-w)$

(补: $P_{xx}(w) = \Phi_{xx}(z)/z = e^{jw}$)

质 { ③ 2π 为周期

$\Phi_{xx}(z) = \sum_{m=-\infty}^{\infty} \sigma_{xx}(m) \cdot z^{-m}$ (Z变换)

(2) 互相关函数, 互功率谱

$$\begin{aligned} \sigma_{xy}(m) &= E[x(n)y(n+m)] \\ \left\{ \begin{aligned} \sigma_{xy}(m) &= \sigma_{yx}(-m) \\ \Phi_{xy}(z) &= \Phi_{yx}(z^{-1}) \\ P_{xy}(e^{jw}) &= P_{yx}(e^{-jw}) \end{aligned} \right. \end{aligned}$$

(3) 白噪声 (均值为 m_x , 方差为 σ_x^2)

$$\begin{aligned} \mathcal{R}: \left\{ \begin{aligned} \sigma_{xx}(m) &= \sigma_x^2 \delta(m) \\ \Phi_{xx}(z) &= \sigma_x^2 \\ P_{xx}(w) &= \sigma_x^2 \end{aligned} \right. \quad (\text{白噪声功率谱无限宽}) (\text{实际上不存在}) \end{aligned}$$

6. 相关卷积定理 (页6, 页20, 页21)

$$\begin{aligned} \text{若 } e(n) &= a(n) * b(n) \xrightarrow{\mathcal{R}} \left\{ \begin{aligned} \sigma_{ef}(m) &= \sigma_{ac}(m) * \sigma_{bd}(m) \\ f(n) &= c(n) * d(n) \end{aligned} \right. \\ &\quad \text{卷积的自相关} \quad \text{自相关的卷积} \end{aligned}$$

应用到
信号处理
中

$$x(n) \rightarrow \boxed{h(n)} \rightarrow y(n)$$

↓

$$\sigma_{yy}(m) = \sigma_{xx}(m) * h(m) * h(-m)$$

7. 求系统特性 (页18, 页27, 页31, 7,

$$x(n) \longrightarrow \boxed{h(n)} \longrightarrow y(n)$$

$$\textcircled{1} y(n) = x(n) * h(n) = \sum_{k=-\infty}^{\infty} h(n-k) x(k)$$

$$\textcircled{2} \phi_{yy}(m) = \phi_{xx}(m) * h(m) * h(-m) = \phi_{xx}(m) * h(-m)$$

$$\textcircled{3} P_{yy}(w) = P_{xx}(w) \cdot H(w) \cdot H^*(w) = P_{xx}(w) |H(w)|^2$$

$$\textcircled{4} \phi_{xx}(m) \longleftrightarrow P_{xx}(w) \text{ (傅里叶)} \quad \phi_{xx}(m) \xleftrightarrow{z} \bar{\Phi}_{xx}(z)$$

$$\textcircled{5} P_{xx}(w) = \bar{\Phi}_{xx}(z) / z = e^{jw}$$

$$\phi_{yy}(0) = m_y^2 + \sigma_y^2 = \frac{1}{2\pi} \int_{-\pi}^{\pi} P_{yy}(w) dw$$

$$\phi_{yy}(00) = m_y^2 / m_y = E[x(n)] = E[x(n) * h(n)] \text{ (一般垂直)} \quad \text{(-一般垂直)}$$

二、Vina

1. 维纳-霍夫方程 (页10, 证明)

$$\hat{g}_{NS}(k) = \sum_{m=0}^{\infty} h_{opt}(m) \hat{g}_{NS}(k-m) \quad k \geq 0$$

2. 维纳滤波 (时) (页29, 页32(1), 页42 → 例题答案), 页40(11)

$$\begin{aligned} J(w) &= E[e_n^2] = d^T d - 2P^T w + w^T R w \quad (\text{大写字母}) \\ J_{min} &= d^T d - P^T w_{opt} = d^T d - w_{opt}^T P \quad (\text{看P是列向量}) \quad w_{opt} = R^{-1} P \Rightarrow P = R \cdot w_{opt} \\ R &= E[z(n) z^T(n)] \quad , \quad P = E[z(n) d(n)] \end{aligned}$$

3. 维纳滤波 (z) (习题) $(x = s + v, s \text{ 与 } v \text{ 不相关})$ (P7, 例2.1, 页19, 页24) (必考是页) ***

$$\textcircled{1} \hat{x}_{NS}(z) = \hat{g}_w^2 B(z) B(z^{-1})$$

$$\textcircled{2} H_{opt}(z) = \frac{1}{\hat{g}_w^2 B(z)} \left[\frac{\hat{x}_{NS}(z)}{B(z^{-1})} \right]_+ \quad \text{因果} \quad \left(H_{opt} = \frac{\hat{x}_{NS}(z)}{\hat{x}_{NS}(z)} \text{ 非因果} \right)$$

$$\textcircled{3} E[e_n^2]_{min} = \frac{1}{2\pi j} \oint [\hat{x}_{SS}(z) - H_{opt}(z) \cdot \hat{x}_{NS}(z^{-1})] z^{-1} dz$$

4. 因果维纳预测值 (N步) $(v=0)$ $d(n) = s_{n+N}$ (页72, 页27, 28)

$$\textcircled{1} \hat{x}_{NS}(z) = \hat{x}_{NS}(z) = \hat{x}_{SS}(z) = \hat{g}_w^2 B(z) B(z^{-1})$$

$$\textcircled{2} H_{opt}(z) = \frac{1}{\hat{g}_w^2 B(z)} \left[\frac{\hat{x}_{NS}(z)}{B(z^{-1})} \cdot z^N \right] = \frac{1}{B(z)} \left[z^N B(z) \right]_+ \quad \downarrow \quad b_{n+N} H(n)$$

$$\textcircled{3} J_{min} = \hat{g}_w^2 \sum_{k=0}^{N-1} b^2(k)$$

5. Yule-walker 方程

2阶预测器]

$$\begin{bmatrix} \bar{x}_m(0) & \bar{x}_m(-1) & \bar{x}_m(-2) \\ \bar{x}_m(1) & \bar{x}_m(0) & \bar{x}_m(-1) \\ \bar{x}_m(2) & \bar{x}_m(1) & \bar{x}_m(0) \end{bmatrix} \begin{bmatrix} 1 \\ a_{p1} \\ a_{p2} \end{bmatrix} = \begin{bmatrix} E[e^2]_{m-1} \\ 0 \\ 0 \end{bmatrix}$$

(考试应该不会再高)

① $a_{pk} = -h(k-1)$ CP步预测器) (与Vina结合, 求 w_{opt})

(页36, 页29)

② (与AR模型结合)

$$a_1 = a_{p1}, \quad a_2 = a_{p2}$$

(页53, 页56, 页60)

$$\begin{cases} H(z) = \frac{1}{1 + \sum_{k=1}^p a_k z^{-k}} \\ x(n) = - \sum_{k=1}^p a_k x(n-k) + w(n) \\ \hat{P}_{xx}(w) = \sigma_w^2 |H(w)|^2 \end{cases}$$

三

① 卡尔曼与维纳区别，卡尔曼的基本思想

页9

2. 新息性质.

$$\tilde{Y}_k = Y_k - \hat{Y}_k \quad (\text{新息})$$

① 新息序列是相互正交的序列: $E[\tilde{Y}_n \cdot Y_k] = 0, \quad 1 \leq k \leq n-1$ (相互正交, 无冗余)

② n 时刻的新息, \tilde{Y}_n , 与过去的观测数据 Y_1, Y_2, \dots, Y_{n-1} 正交.

$$E[\tilde{Y}_n \cdot Y_k] = 0 \quad \{Y_1, \dots, Y_n\} \iff \{\tilde{Y}_1, \tilde{Y}_2, \dots, \tilde{Y}_n\}$$

③ 新息序列 $\tilde{Y}_1, \tilde{Y}_2, \dots, \tilde{Y}_n$ 和数据序列 Y_1, \dots, Y_n 存在一一对应关系, 可相互转化.

③ 又建立状态方程, 观测方程 ^(输出)

(页38)

4. P54页公式, P56页例题

$$x(k) = A_k x_{k-1} + w_{k-1} \quad \text{状态方程}$$

$$y_k = C_k x_k + v_k \quad \text{量测方程}$$

$$\hat{x}_k = A_k \hat{x}_{k-1} + H_k (y_k - C_k A_k \hat{x}_{k-1}) \quad \text{递推公式.}$$

重: 1. 问答.

3. 大题.

其它看有限元聊

四

(最小均方算法)

(不记公式)

1. 最速下降, LMS, RLS (最小二乘法)

LMS

$$① y(n) = \hat{w}^T(n) z(n)$$

$$② e(n) = d(n) - y(n)$$

$$③ \hat{w}(n+1) = \hat{w}(n) + 2\mu z(n) e(n)$$

$$④ \nabla J(w) = -2 z(n) e(n)$$

↓
主要是针对某个题目, 找到对应符号的意义

$z(n)$: 输入向量

$w(n)$: 权向量

$y(n)$: 实际输出 (系统输出)

$d(n)$: 期望输出 (理想值)

$e(n)$: 误差 $\nabla J(w) = E[e^2(n)]$

μ : 步长参数 **

↓

① μ 小了, 收敛速度慢, μ 大了, 会导致发散

② 取值范围: $0 < \mu < \frac{1}{\lambda_{\max}}$, λ 为 R 的特征值 (页41, 页40, 求 λ 范围)

↓
当 μ 在这个范围内时, 算法收敛

最速下降法

$0 < \mu < \frac{1}{\lambda_{\max}}$, λ 为 R 的特征值

$$w(n+1) = w(n) + \mu [-\nabla J(w(n))]$$

$$= w(n) + 2\mu [P - R w(n)]$$

$$\nabla J(w) = -2P + 2R w(n)$$

(页13, 最速下降法, 与 LMS 的区别)

(页32 c2) 根据 LMS 公式求 $w(n)$

(页40 c2) 同上

RLS, $E(k, w) = \sum_{i=1}^k \lambda^{k-i} |e(i)|^2$

$\Phi(n) = \lambda \Phi(n-1) + \lambda^0 z(n) z^T(n)$

遗忘因子,

优点: 收敛快, 收敛速度对R的特征值分布不敏感。

(LMS: 收敛速度与 μ 的取值有关, 而 μ 受R的特征值分布的影响, 收敛较慢)

缺点: 计算量大, $O(n^2)$

(LMS: $O(n)$)

2. 几个概念

① 失调量 (LMS) $M = \frac{T_{ex(\infty)}}{T_{min}} \approx \mu \text{tr}[R]$

② 矩阵条件数:

$\text{cond}(R) = \frac{\lambda_{\max}}{\lambda_{\min}}$, 如果条件数很大, 则R为病态矩阵

③ LMS算法改进(针对收敛慢)

1) 用归化的LMS算法, 将 μ 替换成 $\mu(n) = \frac{\mu}{\|z(n)\|}$, $0 < \mu < 1$

2) 对输入向量 $z(n)$ 作变换, 去掉其相关性(白化), 减小其特征值的动态范围, 从而提高收敛速度

3) 使用子带域自适应方法。

3. 自适应滤波的应用 (画图)

(页44, 页45)

(页55, 页70) (大概率不会考)

五

1. 估计 (页67)

① 无偏估计: $E[\hat{\theta}] = \theta$ $B = \theta - E[\hat{\theta}]$

② 最小方差估计: 最小化 $\sigma_{\hat{\theta}}^2 = E[(\hat{\theta} - E[\hat{\theta}])^2]$, 谁方差小 谁更有效

③ 均方误差: $E[e^2] = B^2 + \sigma_{\hat{\theta}}^2$

④ 一致估计: $N \rightarrow \infty, B \rightarrow 0, \sigma_{\hat{\theta}}^2 \rightarrow 0$

2. 经典谱估计 (BT法, 周期图法) (页64, 经典法 缺点)

① 经典: BT法 (页48)

$$\hat{S}_{xx}(m) = \frac{1}{N-1-m} \sum_{n=0}^{N-1-m} x(n) x(n+m), \quad \text{无偏, 方差大}$$

$$\bar{S}_{xx}(m) = \frac{1}{N} \sum_{n=0}^{N-1-m} x(n) x(n+m), \quad \text{有偏, 方差小, 均方误差小}$$

② 周期图法 (页46, 根绝, 页49证明, 页50续, 页51)

$$S_N(e^{j\omega}) = \sum_{n=0}^{N-1} x(n) e^{-j\omega n}$$

$$I_N(\omega) = \frac{1}{N} |S_N(e^{j\omega})|^2, \quad \text{有偏, 不是一致估计}$$

$$\hat{P}_{xx}(\omega) = I_N(\omega)$$

改进 (从信号角度看) (页46)

Bartlett 平均周期图法, 方差降为原来的 $\frac{1}{L}$.

3. L-D 递归算法

$$\sigma_k^2 = (1 - |a_{kk}|^2) \sigma_{k-1}^2, \quad |a_{kk}| \text{ 为反射系数 } |a_{kk}| < 1$$

时间复杂度: $O(P^2)$

P 为矩阵阶数

矩阵求逆: $O(P^3)$

4. 参数估计 (页63, 页65, 页68, 页65) $w(n) \rightarrow \boxed{h(n)} \rightarrow x(n)$

① 参数化模型

$$\begin{cases} \text{ARMA}(p, q) \text{ (峰谷)} \\ \text{MA}(q) \text{ (谷)} \\ \text{AR}(p) \xrightarrow{\text{(峰)}} \end{cases}$$

(rule-walker)

计算大是更(必考) 与线性预测结合
(页53, 页56, 页60)

$$\begin{aligned} H(z) &= \frac{1}{1 + \sum_{k=1}^p a_k z^{-k}} \\ x(n) &= - \sum_{k=1}^p a_k x(n-k) + w(n) \\ \hat{P}_{xx}(w) &= \sigma_w^2 |H(w)|^2 \end{aligned}$$

② 模型阶数 (p)

高: 会产生虚假的谱峰
低: 分辨率低

当达到 p 阶后, 方差不再下降, 即 $\sigma_1^2 > \sigma_2^2 > \dots > \sigma_p^2 = \sigma_{p+1}^2 = \sigma_{p+2}^2 = \dots = \sigma_w^2$

③ 最大高频谱估计 (不考计算)

1) 思想: 已知 $G_{xx}(0) \dots G_{xx}(p)$, 对 $m > p$ 的 $G_{xx}(m)$ 进行外推, 所推后的自相关所对应的序列具有最大的高频。

2) 与AR的关系: 当 $x(n)$ 为高斯分布时, AR模型与最大高频谱估计等价。

5. 前向预测与后向预测

↓ 参数相同

$$\hat{x}(n) = -\underline{a_{p1}}x(n-1) - a_{p2}x(n-2) \cdots - \underline{a_{pp}}x(n-p)$$

$$\hat{x}(n-p) = -\underline{a_{p1}}x(n-p-1) - \cdots - \underline{a_{pp}}x(n)$$

6. 最小方差法

① 其角不是真正的功率谱，其角解的反变换不等于 $x(n)$ 的自相关。

② 同阶次的 Capin 谱估计分辨率低于 AR 估计。